프로젝트7 Data Science ML _ Overview

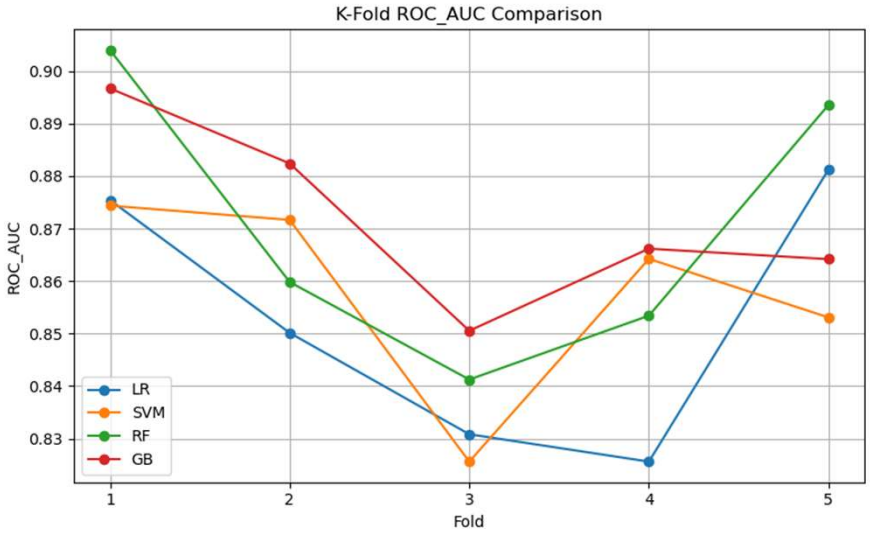

개요

프로젝트명	Data Science ML
개발 기간	2025.9 ~ 2025.12
Tool	Anaconda, Python, Pandas, Scikit-learn
관련 수업	데이터 사이언스

소개

데이터사이언스 수업에서 진행한 프로젝트로, Python, Scikit-learn, Pandas를 활용하여 타이타닉 생존자 예측 모델을 구현하고, 잡코리아 데이터를 기반으로 구인구직 시장 분석을 수행했습니다.

개발 순서

-데이터 수집
-데이터 전처리
-데이터 탐색 및 시각화
-모델링
-결과 분석 및 평가
-결론 및 인사이트

프로젝트7 Data Science ML _ Job Market 분석

Job Market 분석

데이터 수집/분석

1.동적 페이지 크롤링 및 데이터 수집
Requests를 사용하여 잡코리아의 검색 결과 페이지를 파싱하는 parse_jobkorea_page 함수를 직접 구현하였다.

2.데이터 정제 및 구조화
수집된 리스트 데이터를 Pandas DataFrame으로 변환하고, drop_duplicates()를 사용해 중복된 공고를 제거하여 데이터의 정밀도를 높였다.

3.데이터 분석 및 시각화
지역별, 직무 키워드 별로 분석하였다.
앞서 정제한 데이터프레임의 열의 빈도수를 계산하여 시각화하고 특정 지역에 데이터 직무가 편중되어 있음을 확인하였다
직무 키워드의 경우, 공고 제목에 포함된 텍스트를 re 라이브러리로 분리하고 Counter 모듈을 사용해 상위 20개 핵심 키워드를 추출하여 구체적인 요구사항 파악하였다.

4.분석
데이터 사이언티스트 채용은 서울 강남 지역과 판교 등 IT 클러스터에 압도적으로 집중되어 있음을 수치로 확인하였다. 또한, '시니어', '엔지니어', '데이터분석가' 키워드가 상위에 위치하여, 단순 분석 역량뿐만 아니라 엔지니어링 역량과 경력직 위주의 시장 환경을 읽어낼 수 있었다.

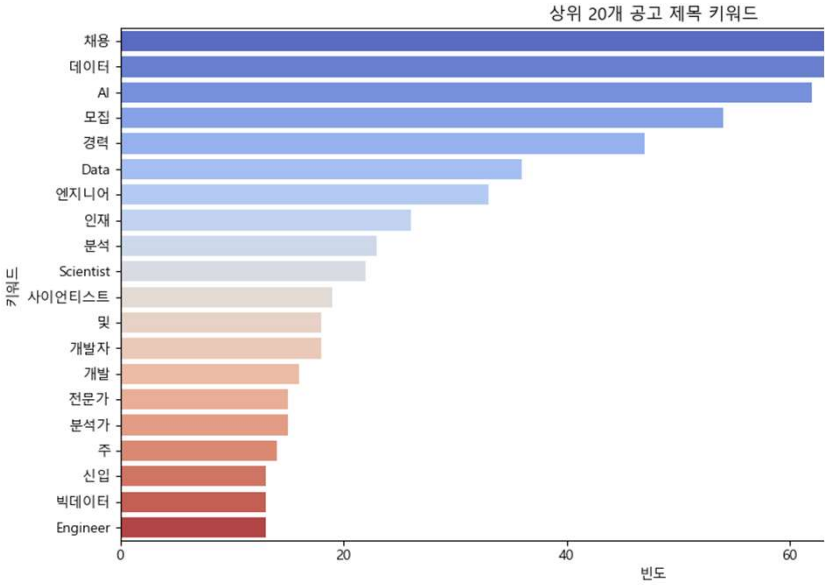

프로젝트7 Data Science ML _ Titanic 탑승객 분석

Titanic 탑승객 분석

데이터 수집/분석

1.데이터 수집
Kaggle Titanic Dataset을 활용하였다.
탑승객의 인적 사항(성별, 나이, 객실 등급등)과 생존 여부를 포함한 데이터 포함한다.

2.데이터 전처리
데이터의 정제와 수치화를 통해 모델이 학습 가능한 상태로 만들었습니다.
결측치를 처리하고, 중복되는 Feature는 합쳐 하나로 만들고, 범주형 변수는 원-핫 인코딩을 적용하여 데이터를 변환하였다.

3.모델 학습
우선, Logistic Regression을 구현하였고, Full-batch와 Mini-batch 방식의 Loss 변화를 비교하였다
Mini-batch 방식이 초기에 빠르게 Loss를 감소시키며 효율적으로 수렴함을 확인하였다.

이후 SVM, Random Forest, Gradient Boosting 모델을 추가 학습시켜 성능을 비교하였다.
Accuracy, F1-Score, ROC-AUC 3가지 지표를 사용하였다.

4.분석
Gradient Boosting
ROC-AUC와 F1-Score에서 가장 높은 수치를 기록했으며, 튜닝 전후로도 가장 안정적인 성능을 보여 최종 모델로 선정했다.

Gradient Boosting 학습하는 과정에서,초기 설정된 높은 반복수로 인해 다른 모델 대비 학습 시간이 비정상적으로 길어지는 현상이 발생했다. Boosting 알고리즘 특성상 이전 단계의 오차를 순차적으로 학습해야 하므로, 반복수가 늘어날수록 연산 비용이 기하급수적으로 증가함을 파악하였다.
무조건적인 반복보다는 성능과 시간 사이의 균형을 맞추기 위해 반복수를 적절히 하향 조정하였다.

Model	Accuracy	F1 Score	ROC-AUC
Logistic Regression	0.7924	0.7216	0.8526
Random Forest	0.8215	0.7646	0.8704
SVM	0.8271	0.7536	0.8578
Gradient Boosting	0.8373	0.7716	0.8720

프로젝트7 Data Science ML _ 결과물

Job Market

시행착오

잡코리아 웹사이트에서 직무 공고의 데이터를 정확히 추출하기 위해 복잡하게 얽힌 HTML 태그 구조를 분석하였다. 개발자 도구를 활용하여 단순히 눈에 보이는 텍스트가 아니라, 데이터가 일관되게 담기는 클래스명과 식별자의 패턴을 찾아내어 추출 규칙을 설계하였다.
구조 분석을 했던 경험 덕분에, 대학 강의 수강 사이트에서 강의 정보가 담긴 특정 URL과 데이터 위치를 즉각적으로 파악할 수 있었다.

결과물
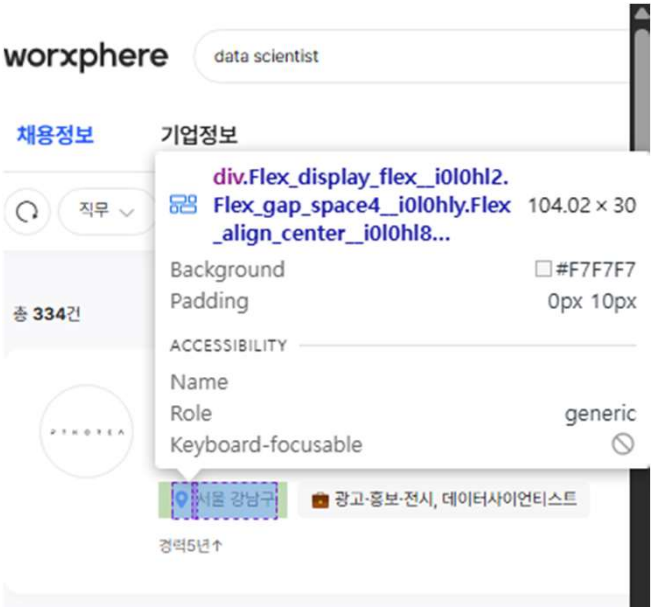
[Data Science ML]
https://github.com/J-Shin01/DataScience_ML/tree/main